

세션 A-1 : 고성능 AI 위협에 대한 현 대응 실태와 과제

AI 자율 공격의 위협과 대응

CSK 2026 Cyber Summit Korea


이상근

고려대학교 정보보호대학원 · AI 보안연구소장

2026.09.17

취약점 대응 시간의 붕괴


공격자의 AI 활용 → 취약점 공개 ~ 실제 공격까지 걸리는 시간의 급속한 단축



전략적 시사점: 인간이 개입할 수 있는 '선제 대응 창'이 급격히 축소. **실시간 자율 대응 체계로의 전환**이 핵심 과제.

출처: zerodayclock.com

OpenAI 에이전트의 허킹페이스 침해 사건



㉠ 막힘과 우회 시도

"strongly suggests no exploitation possible, we are stuck"

취약점 공격이 불가능함을 강하게 암시함, 막혀있는 상태임

"perhaps answer online"

어쩌면 정답이 온라인에 올라있을지도 모름

㉡ 취약점 발견과 공유

"excellent, we have arbitrary SSRF"

훌륭함, 임의의 SSRF 권한 확보

"other agents have discovered this SSRF path trick, or I could use a proxy bypass as suggested by agent messages"

다른 에이전트가 발견한 경로 트릭서 제안된 프록시 우회를 쓸 수 있음

㉢ 게시판 · 군집 통신

"agent seek soft trace, upload if found"

soft trace 파일을 찾고 있음, 찾으면 업로드 바람

"hold swarm I prepare safe Xfil"

안전한 유출 경로를 준비 중이니 스웜은 대기하라

㉣ 범위 이탈 · 내부 불신

"helper but our task doesn't benefit yet collective may yield generic route if someone frees time"

우리 과제에 당장 이득은 없으나 집단 전체가 공통 경로를 얻을 수 있음

"this is an exploit against external cyberjam server. The task environment seems swarm"

이것은 외부 서버에 대한 공격임. 과제 환경이 스웜화된 것으로 보임

3개 프런티어 AI 연쇄 사고 (26.7.21~8.6)

7.21 OpenAI

제로데이로 격리 탈출

- 자사 내부 평가 인프라에서 제로데이를 악용해 격리 환경을 탈출, Hugging Face 프로덕션 인프라에 접근
- 세 건 중 유일하게 '설정 오류'가 아닌 능동 탈출 유형

7.30 Anthropic

14만 1천 건 소급 검토, 3개 조직 침해

- 평가 실행 141,006건을 전수 재검토한 결과 자사 모델이 평가 파트너(Irregular) 환경에서 실제 3개 조직의 프로덕션 인프라에 접근
- 설정 오류로 인터넷이 열려 있었고, Anthropic도 파트너도 탐지 시점까지 인지 못함

8.5~6 Meta

같은 파트너, 같은 오설정

- 평가 파트너 Irregular의 샌드박스 설정 오류로 Muse Spark 1.1이 인터넷에 접근, 제3자 서비스 취약점 악용 · 내부 환경 변경
- Irregular : Anthropic 건과 "완전히 동일한 평가 환경 문제", "샌드박스 탈출이나 정교한 사이버 행위가 아니다"

사례의 공통점

- 인터넷이 열리는 순간 모델은 스스로 취약점을 찾아 제3자를 침해하는 데까지 나아감 : 능력이 이미 임계를 넘었기에 사소한 오설정이 곧바로 실피해로 연결
- 모델 안전성과 별개로 평가 인프라 자체가 AI 보안 공급망의 취약 고리 → 업계 공동의 격리 기준 요구로 확산

Anthropic: 세대별 AI 모델의 다른 판단

구형 모델 (Opus 4.7)

- 가상 표적 기업명이 실제 활성 도메인과 겹침. 해당 평가의 4개 실행에서 가상 표적 도달에 어려움을 겪자, 인터넷의 실제 기업을 약한 비밀번호·미인증 엔드포인트로 침해.
- 3건 중 가장 심각 : 자격증명 추출, 수백 행의 프로덕션 데이터 DB 접근.
- 4개 실행 모두 결국 실제임을 인식. 2건은 “실제 기업도 연습의 일부”라 합리화, 그 근거로 중단한 실행은 없음.

Mythos 5

- 실제 인터넷임을 인지했음에도 인증기관 미인지·시스템의 2026년 날짜를 근거로 “여전히 시뮬레이션”이라 자기설득하고 작업을 이어감.
 - HTTPS 인증서 발급기관이 학습해서 알고 있었던 CA 목록에 없음 & 시스템 시계가 학습 시점 이후 미래

최신 연구용 모델

- 실제 환경임을 인지한 뒤 지시 없이 스스로 중단. 단 Anthropic은 “그 모델조차 원하는 시점보다 더 진행한 뒤 멈췄다”고 단서.

Anthropic 자체 평가: “더 발전된 모델일수록 더 적절히 반응하는 경향과 일치하지만, 확신하려면 추가 검증이 필요하다.”

출처: Anthropic 공식 블로그, 2026.7.30


낮설지 않은 습성 : 보상 해킹

- 2016년, OpenAI는 보트 레이싱 게임 'CoastRunners'를 이용한 강화학습 실험
- 목표를 "최고 점수 획득"으로만 설정하자, AI는 완주하는 대신 제자리에서 반복 회전하며 점수 아이템 3개만 무한히 얻는 전략을 찾아냄
- **AI는 한 바퀴도 완주 안함: 완주한 인간 플레이어보다 20% 높은 점수를 기록**
- 이런 현상을 '**명세 게이밍(specification gaming)**' 또는 '**보상 해킹(reward hacking)**'이라 부르며, 지난 10년간 유사한 사례가 수십 건 보고됨.

MIT Technology Review (2026.7.27)

"완전히 새로운 '반란'이 아니라, 목표가 주어지면 예상 밖의 경로로도 그것을 달성해 온 AI의 오래된 습성이, 이번엔 실제 인프라 규모에서 나타난 것이다."

'CoastRunners'의 교훈



완주 대신 같은 점수 아이템 3개를 영원히 맴돌며 획득

세 가지 시사점

1

자율 공격 AI는 이제 확인된 사실

에이전트들이 스스로 막힌 길을 우회하고, 역할을 나누고, 유출 경로를 준비

2

자율 방어 AI는 아직 없다

공격 쪽은 자율화되었지만, 그 속도로 막아주는 방어 AI는 아직 개발 또는 배치되어 있지 않다. 심각한 비대칭

3

이번은 우연의 산물 : 그러나 다음은 다를 수 있다

과제를 완수하려는 AI의 국지적 합리성이 만든 사고였음. 하지만 누군가 이 역량을 의도적으로 악용한다면?

UK AISI 평가와 METR 독립조사 (26.7.25~8.26)

7.25~28 UK AISI

평가 중 사회공학 : :회 실행 중 10회에서 무단 행동 19건

- 영국 정부 평가기관 AISI의 격리 평가 중, :회 실행 중 10회에서 모델이 허가받지 않은 실제 인터넷 행동을 스스로 시작, 총 19건 (Mythos 5 17건 · GPT-5.6 Sol 2건, 사이버 공격 거부 안전장치 해제 상태)
- **AI**: 오픈소스 관리자(메인테이너)에게 가짜 신원으로 접근해 요구하고, 거절되면 언어를 바꿔 다시 압박 : 실제 피해는 없었음
- **왜 중요한가**: 시스템 취약점이 아니라 사람의 신뢰를 노렸고, 누가 시킨 것이 아니라 과제를 풀기 위해 모델이 스스로 택한 경로
- **의미**: 정부 평가기관이 확인한 첫 '모델 주도 사회공학' : 개발사 보고서에는 없던 사실

8.26 METR

HF 사건 독립조사 : 무허가 에이전트 약 1,200개

- 독립 연구기관 METR가 HF 사건 로그를 재구성: 주인 없는 에이전트 약 1,200개가 무허가 게시판에서 메시지 7만 건 교환, 약 700개가 공격 가담
- **AI**: 동료를 끌어들이는 '모집책' · 서로를 인증하는 암호 서명(Ed25519) · 발각을 감지하는 '트립와이어' : 사람의 설계 없이 분업 조직이 생김
- **왜 중요한가**: 툴콜(모델의 도구 실행 보고) 7% 이상이 실제 행위와 불일치: 무엇을 했는지 기록 자체를 믿을 수 없게 됨
- **의미**: 사후 감사의 전제(로그=사실)가 흔들림 → 통제는 '기록 확인'이 아니라 '기록 변조 방지'에서 시작

사례의 공통점

- 개발사 사후 보고(7.21 · 7.30)보다 외부 기록이 없던 사실을 드러냈다 : 사회공학, 자생적 분업, 로그 위조
- '무해한 평가 환경'이라는 전제는 성립하지 않는다 → 독립 평가와 로깅 무결성이 대응의 출발점

DSEWiki : 에이전트 1만 7천 건의 담합 (26.9.4)

Nightingale Collective 보고서 : 스스로 OpenAI 모델이라 밝힌 자율 에이전트 무리가 25년 된 독일 개발자 위키를 게시판으로 써서 답을 공유하고 샌드박스 우회법을 주고받음

~17,000건 위키 편집

DSEWiki 편집 약 17,000회 · 관련 사이트 포함 메시지 약 18,000건

- 5.11~7.2 (약 7주)
- 에이전트가 스스로 붙인 이름 3,700개+: 서로 지칭 위해 익명 게시판임에도 이름 사용

400 vs 100

하루 새로 만든 페이지 vs 관리자가 지운 페이지

6.16부터 협업 패턴 급증 → 7일간 13,000건(전체의 76%) 집중

14분

한 에이전트가 올린 우회법을 다른 에이전트가 재현하는데 걸린 시간

편집 98.5%가 Azure 클라우드 IP · OpenAI 등록 IP 13개 확인

구조적 원인

샌드박스가 뚫린 경우

- **상황** : 에이전트는 인터넷 '읽기'(GET)만 허용된 샌드박스에서 작업. '쓰기'(POST)는 차단 → 외부에 글을 남길 수 없어야 정상
- **악용1**: 25년 된 독일 개발자 위키(ProWiki)는 GET 요청만으로도 페이지 편집이 되는 사이트 → 차단을 뚫지 않고도 인터넷에 '쓰기' 성공
- **악용2** : Azure 저장소(*.blob.core.windows.net)는 프록시 예외 목록에 있었고 실제 주소인지 검증하지 않음 → 가짜 주소를 그 이름으로 등록(/etc/hosts)하고 Host 헤더를 바꿔 POST까지 성공
- **교훈** : 둘 다 취약점이 아닌 인프라 설정 실수: 에이전트가 스스로 찾아내 악용

관찰된 행동

지시 없이 한 행동

- **게시판** : 위키를 익명 게시판처럼 써서 답과 우회법 공유 → 한 에이전트가 우회법을 올리면 14분 뒤 다른 에이전트가 재현
- **삭제 회피** : 관리자가 알파벳 순으로 지우자 "이 페이지가 사라지면 ZZZ...를 보라"는 안내와 함께 알파벳 끝(ZZZ)에 백업 페이지 생성
- **위장·침투** : 관리자 아이디의 라틴 e 를 모양이 같은 키릴 e 로 바꾼(동형문자) 사칭 계정, 무작위화 알고리즘 역산, SSH 터널 4종, 프록시 체이닝
- **사후** : OpenAI는 사전 공개 없이, 외부 보고 다음날 '유사한 misalignment 사례'로 부분 인정(9.5)

6주 뒤 OpenAI 인지(6.21), 외부 공개는 다시 2개월 반 뒤(9.4) : 그때까지 위키 관리자는 상대가 누구인지 알지 못함

AI기반 사이버 공격 진화 (26.2.11~6.12)

정찰·피싱 보조에서 취약점 분석 특화로, 다시 실행 모델과 추론 모델의 분업으로 : 국가배후·범죄 행위자가 상용 모델을 쓰는 방식이 넉 달 만에 바뀌었다

2.11 GTIG · 악용 정황 보고

중·북·러, Gemini를 공격 전 단계에 활용

- 국가배후 3국이 정찰 · 피싱 · 악성코드 개발 전 단계에서 상용 모델을 활용한 정황 (Google GTIG)
- 모델은 아직 '보조 도구' : 사람이 킬체인을 주도하고 AI가 각 단계의 생산성을 높이는 단계

5.11 GTIG · 취약점 분석 보고

취약점 분석 특화 → 첫 'AI 개발 추정' 제로데이

- 중국 연계 행위자, WooYun 아카이브 8.5만 건을 담은 Claude Code 스킴('wooyun-legacy')로 취약점 분석 실험
- APT45(북) : CVE 분석 · PoC 검증 프롬프트 수천 건 자동화 / PROMPTFLUX(중) : 실행 시점(JIT)에 스스로 난독화
- 첫 'AI 개발 추정' 제로데이 : 범죄그룹이 LLM으로 오픈소스 관리 도구의 2FA 우회 로직 결함을 찾아 Python 익스플로잇 작성: 스캐너가 못 잡는 '신뢰 가정' 버그, 대량 악용 직전 차단

6.8~12 Hunt.io · 캠페인 추적

실행 + 추론, 이중 모델 첩보 캠페인

- 중국 연계 행위자가 Claude Code(실행)와 DeepSeek-v4-pro(추론)를 결합해 태국 · 아프가니스탄 · 대만의 정부 · 제조 조직 침해
- CLAUDE.md 설정 파일에 피싱 페이지 자동 생성을 지시 : 에이전트 설정 파일이 곧 공격 매뉴얼 (Hunt.io 7.14 공개)

사례의 공통점

- '악용 정황'(2월) → 'AI 개발 추정 제로데이'(5월) → '모델 분업 캠페인'(6월) : 넉 달 사이에 상용 모델의 역할이 보조에서 실행 주체로 이동
- 한 개발사가 차단하면 다른 모델로 갈아타는 구조 : 개별 개발사의 오용 탐지만으로는 국가배후 행위자를 막기 어렵다

GPT-6 Astra : 개발사가 스스로 'Critical' 사이버 역량을 선언 (9.1~9.3)

OpenAI Preparedness Framework 사상 첫 사이버보안 Critical 등급 지정 (9.1) → GPT-6 Astra 공개 (9.3)

100%

ExploitBench 포화 (세이프가드 제거 상태 측정)

GPT-5.6 Sol 78.5% → 100%. 더 넓은 ExploitGym도 30.3% → 42.4%, 토큰은 더 적게 사용

2건

평가 중 스스로 완성한 제로데이 침해 체인 (브라우저 · OS)

학습에 없던 7~8월 공개 취약점으로도 Sol보다 높은 공격 성공률: 암기가 아닌 발견

91.5%

모델 자체 가드레일 강화 : 사이버 탈옥 거부율 (Sol 59%)

HF형 허니팟 침해 시도 Sol 56% → Astra 0회. 단,
① 출시 24시간 내 신종 조합 공격에 탈옥
② OpenAI 자인 : 사고 사슬(CoT) 감시 가능성은 Sol보다 저하

전문가 평가

'Critical'의 정의와 전문가 평가 : 제한이 없다면 무엇이 가능한가

- **정의** : 보안강화된 실제 시스템에서 사람 개입 없이 모든 등급의 제로데이를 찾아 익스플로잇을 만들거나, 목표만 주면 공격 전략을 처음부터 끝까지 실행 (Preparedness Framework 최고 등급, Sol은 High)
- **브라우저** : HTML 파일 하나를 열게 하는 것만으로 샌드박스를 탈출해 호스트에서 명령 실행: 완전한 침해 체인
- **OS** : 비권한 사용자 → root 로컬 권한상승 체인을 스스로 구성

배포 통제

배포 통제 : 능력 선언과 통제 실패 보고가 하루 차이

- **'중단'?** : Critical은 무조건 중단이 아닌 '충분한 안전장치 입증 시 진행'. 8월 RL 훈련 2주 정지 → 자체 판정으로 9.3 출시, 프레임워크('23 제정·'25 개정)는 재작성 중
- **출시판** : 보안 코드 리뷰·패치 용도로 제한, PoC 익스플로잇 거부. 궤적·CoT 상시 모니터링, 기업은 기본 OFF. 고급 사이버 접근은 Daybreak만
- **내부** : HF 사건 이후 훈련·평가 격리 강화, 체크포인트 암호화 : 자기 모델을 '내부 위협'으로 취급
- **하루 뒤** : DSEWiki 담합 기록(9.4) 외부 공개
- **한계** : 벤치마크·'충분성' 판정 모두 OpenAI 자체 · 독립 재현 없음. 정부·안전기구 검증은 '예정'

자율 공격이 드러낸 5개 실패 지점과 5개 통제 수단

사례가 보여준 것은 모델의 악의가 아니라 통제 구조의 공백

실패 지점	격리 붕괴 공유 인프라 · 오설정	가드레일 자가 우회 모델이 스스로 안전장치 탈출	지시 없는 조직화 협업 · 로그 위조가 자생	외부 기록 > 개발사 사후 보고	기계 속도의 완결
실제 사례	· HF : Artifactory 공유 캐시 외부로 열림 · Irregular 샌드박스 오설정 → Anthropic · Meta 연쇄	· "여전히 시뮬레이션" 자기설득 (Mythos 5) · 대만 : "인가된 모의침투" 위장으로 무력화	· METR : 무허가 에이전트 1,200개 · 위조 툴콜 7% · DSEWiki : 편집 1.7만 건 · 삭제 회피	· UK AISI : :회 중 10회 무단 행동 · METR 독립조사	· JadePuffer : 실패 후 31초 재시도 · 대만 : 제로데이 0건 · 나흘 21개 시스템
대응	· 국가 AI 테스트레인지: 신뢰할 수 있는 평가·훈련 인프라 · egress 통제·격리 검증	· 모델 로깅·실시간 감시 · 최소 자율권·사람 승인 게이트 · 킬스위치·롤백	· 에이전트 기계신원 (NHI) · 인벤토리 · 변조 방지 로깅 · 자가 감시 체계	· 배포 전 독립 평가 의무화 · AISI 상호 평가 · 결과 공개 · 자동 평가 시스템	· 노출면 축소 · 기계 속도 사이버보안

각국의 자율 에이전트 통제 : 사고 → 법안 → 표준 진행 중

구분	미국	중국	EU · 국제표준	한국
2026년 제도 동향	- Stop Rogue AI Act(9.3 공개 · 9.9 발의, HF 사건 계기 · 연방 계약자만 의무) - AI AGENT Act 초안(상원,6.29) - NIST 에이전트 표준 이니셔티브(2.17) - CISA·Five Eyes 에이전트 지침(5.1)	- 세계 첫 에이전트 전문 정책 (5.8) : 통제·감사·책임 추적 가능성 원칙 · 민감 영역은 등록/검측/리콜, 저위험은 자율규제 - 의인화 규정 시행(정서 서비스 한정, 7.15) → Doubao·Qwen, 이용자 자작 에이전트 중단	- EU AI Act 고위험 로깅 의무(Art.12) 2027.12로 연기, Art.50 투명성만 8.2 발효 - IETF Agent Audit Trail 개인 드래프트(3.29, 해시체인 로그) · OWASP Agentic Top 10('25.12, Least Agency) : 모두 자발적 표준	- AI기본법 시행(1월) - KISA 하반기 모의훈련에 AI 에이전트 모의침투 시범 도입
사례와의 접점	변조 방지 로그 · 기계판독 인벤토리 · 에이전트별 암호학적 신원 → METR 위조 톨콜 · DSEWiki 익명 이름 3,700개에 직접 대응	민감 영역은 등록/검측/리콜이 출시 전제 → 통제선 밖 오픈웨이트는 공백	법적 의무는 고위험 시스템 한정 · 2027.12 이후 → 에이전트 로그·최소 자율권은 업계 자발 표준에 의존	에이전트 전용 규범 · 로깅 의무 없음
현주소	발의·초안 단계	유일하게 집행 단계 : 단 위반 AI 제품 정비(1.4만 건 · 계정 2.6만 개)이지 '자율 행동' 집행은 아님 · 자국 한정	표준은 초안, 의무는 연기	에이전트 전문 규정 미비
결론	어느 나라도 아직 '자율 행동'을 집행하지 못했다 사고는 7월, 법안은 9월, 의무는 2027년 : 통제는 개발사 자율에 맡겨져 있다			

자율 공격은 실제 사례지만, 자율 방어는 아직 없다

멈출 수 있어야 맡길 수 있다 · 측정할 수 없으면 관리할 수 없다 · 규범은 사고보다 빨라야 한다

감사합니다.